

基于压缩感知的 DCE-MRI 重建与基于 GPU 的 MRF 字典生成和匹配

答辩人：王冬
指导教师：杨孝平 教授

南京理工大学
理学院

2019 年 6 月 11 日

目录

- ① 引言
 - 研究背景
 - 主要工作
- ② 胸部 DCE-MRI 图像压缩感知的时间稀疏正则项的量化评估
 - 时间稀疏项
 - 实验结果
- ③ 动态 MRI 图像的低秩和稀疏分解模型
 - 基于 TGV_{α}^2 与核范数的压缩感知重建模型
 - 实验结果
- ④ 基于 GPU 的实时磁共振指纹的字典生成和匹配
 - GPU 程序实现
 - 实验结果

研究背景-压缩感知 MR 重建

- 基于压缩感知的 MR 重建是近十几年研究的热点。
- 压缩感知理论表明，可以从少量 k-space 数据中通过算法精确地重建出 MR 图像
- MRI 成像速度慢，而压缩感知可以加速 MR 成像，因此在临床和研究上都有着重要的意义。

研究背景-压缩感知 MR 重建

基于压缩感知的 MR 重建模型:

$$\min_X \frac{1}{2} \|AX - B\|_F^2 + \alpha \|TX\|_1 \quad (1)$$

其中 X 为待重建的 MR 图像, B 为采样收集到 k-space 数据, T 为某个稀疏变换。

这里 $A = M \cdot \mathcal{F}$ 为采样矩阵, 其中 \mathcal{F} 为傅里叶变换, M 为采样模式。

研究背景-压缩感知 MR 重建

- 常用的稀疏项：傅里叶变换、小波变换、TV/TGV、核范数、字典学习、深度神经网络...
- 常用的采样方式：Cartesian、伪径向/径向、螺旋...
- 常用的重建算法：ADMM、FISTA、Primal-Dual ...

研究背景-压缩感知 MR 重建

压缩感知 MR 重建存在的问题:

- 对于胸部 DCE-MRI(磁共振动态对比增强), 其稀疏项不确定, 尤其是时间方向上的稀疏项
- 使用 TV 作为正则项重建出的 MR 图像存在阶梯效应, 边界不清的问题
- 动态 MR 图像的时间分辨率与空间分辨率之间权衡
- ...

研究背景-MRF

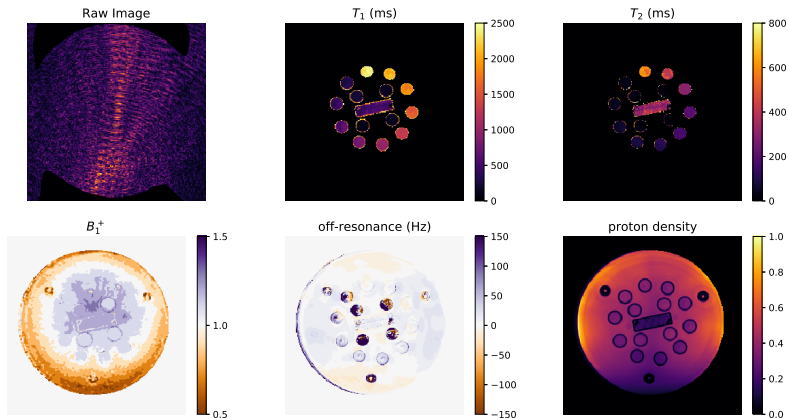
- 磁共振指纹 (MRF) 是一种新的定量 MRI 方法
- 可以在单次数据采集中同时获取多个组织参数, 如 T_1 , T_2 和质子密度
- 这些参数可以为医生提供更加客观的标准, 增加诊断的精度

研究背景-MRF

MRF 重建参数图的过程中涉及到三个步骤，分别为信号采集、预定义字典生成和模板匹配。

- 选取对所需参数敏感的 MR 序列对信号进行采样，并且序列的参数，如重复时间 (T_R) 等，需要随着时间随机变动，使得不同参数的组织在 MR 序列中产生独特的信号演化 (指纹) – bSSFP/uSSFP ...
- 字典中包含着不同参数的组织在该 MR 序列中的模拟演化 – EPG/Bloch ...
- 模式识别算法用来比较每个体素指纹和字典中元素的匹配度，重建参数图 – 模板匹配、降维 (SVD/grouping)、深度神经网络...

研究背景-MRF



研究背景-MRF

MRF 重建的主要问题:

- 字典生成和模板匹配的速度慢, 当字典比较大时, 通常需要几十分钟甚至几小时。
- 临床中还无法应用, 需要快速甚至实时的算法和软件

主要工作

- 针对胸部 DCE-MRI 图像，比较了 5 中不同的时间方向的稀疏项，并对结果进行了定量分析，确定了适合胸部 DCE-MRI 的时间稀疏项
- 针对胸部 DCE-MRI 图像，利用提出了基于二阶 TGV 和核范数的稀疏低秩分解模型
- 针对 MRF 中字典生成和匹配速度慢的问题，开发了一款基于图形处理单元 (GPU) 的开源软件 snapMRF

发表的论文

- Dong Wang, Lori R. Arlinghaus, Thomas E. Yankeelov, Xiaoping Yang, and David S. Smith. Quantitative Evaluation of Temporal Regularizers in Compressed Sensing Dynamic Contrast Enhanced MRI of the Breast. (EI, 接收)
- Dong Wang, Jason Ostenson, and David S. Smith. snapMRF: GPU-Accelerated Magnetic Resonance Fingerprinting Dictionary Generation and Matching using Extended Phase Graphs. (SCI 三区, 重投)
- Dong Wang and Xiaoping Yang. Compressed sensing based DCE-MRI of the breast reconstruction using low rank and sparse decomposition. (在写)

发表的会议

- Dong Wang, Lori R. Arlinghaus, Thomas E. Yankeelov, Xiaoping Yang, and David S. Smith. Quantitative Evaluation of Temporal Regularizers in Compressed Sensing Dynamic Contrast Enhanced MRI of the Breast.(ISMRM,2017)

- 1 引言
- 2 胸部 DCE-MRI 图像压缩感知的时间稀疏正则项的量化评估
- 3 动态 MRI 图像的低秩和稀疏分解模型
- 4 基于 GPU 的实时磁共振指纹的字典生成和匹配

时间稀疏项

- 磁共振动态对比增强 (DCE-MRI) 是通过测量注入造影剂期间和之后的信号，使得图像的每个体素产生一个时间强度曲线，用于定量地估计生理参数，如例如体积转移常数 (K^{trans}) 和血管外细胞体积分数 (v_e) 等
- 这些生理参数有助于给医生提供客观的标准，用于诊断和治疗
- 对于胸部 DCE-MRI，体素的时间强度曲线决定了参数估计的准确性，高时间分辨率有利于提精确地定量分析

时间稀疏项

- 虽然压缩感知已经应用于胸部 DCE-MRI 中，但目前还没有研究通过量化分析的方式来比较时间方向的稀疏项在 DCE-MRI 中的表现
- 因此对于定量胸部 DCE-MRI，不同时间方向的稀疏项对重建误差的影响是未知的

时间稀疏项

本文通过量化分析的方式比较和评估 5 种不同的时间方向的稀疏项 T :

- ① 傅里叶变换的 l_1 范数 (l_1 -norm of the Fourier transform, FT),
- ② 希尔小波变换的 l_1 范数 (l_1 -norm of the Haar Wavelet transform, WT),
- ③ 全变差 (Total Variation, TV)
- ④ 二阶 TGV (Second Order TGV, TGV_α^2),
- ⑤ 核范数 (Nuclear Norm, NN)。

时间稀疏项

- 图像大小 $192 \times 128 \times 105$
- 采样模式为 200 个不同的 Cartesian 采样
- 使用 FISTA 求解
- 评价标准为图像的增强信噪比 (SER) 和肿瘤区域参数的一致性相关系数 (CCC)

在每一帧图像上，我们对低频区域进行全采样，对高频区域进行随机采样。




Figure: Cartesian 采样模式的例子

实验结果

NN 得到了最高的 SER，而 TV/TGV $_{\alpha}^2$ 得到了最高的 CCC，即它们在肿瘤区域的重建效果最好。

Table: 200 个 Cartesian 采样模式重建的均值 SER 与 CCC

稀疏项	SER(dB)	CCC{K ^{trans} }	CCC{v _e }
Zero Filled	15.1	0.694	0.636
FT	26.4	0.763	0.575
WT	21.8	0.878	0.733
TV	27.7	0.974	0.916
TGV $_{\alpha}^2$	27.8	0.974	0.917
NN	29.1	0.842	0.799

实验结果




Figure: 第一个 Cartesian 采样模式下第 105 帧的重建结果。图中的红色的箭头显示，在视觉上，NN 去除背景伪影方面表现最好。

实验结果




Figure: 第一个 Cartesian 采样模式下第 1 帧的重建结果。图中的红色的箭头显示，在视觉上，TV 和 TGV_{α}^2 模型重建肿瘤的效果是最好的。

实验结果




Figure: K^{trans} 和 v_e 参数肿瘤部分放大后的图像。在视觉上，TV 和 TGV_{α}^2 与全采样的参数图像最接近。

实验结果




Figure: 全采样图像与重建图像肿瘤区域像素时间曲线的比较图。

- 1 引言
- 2 胸部 DCE-MRI 图像压缩感知的时间稀疏正则项的量化评估
- 3 动态 MRI 图像的低秩和稀疏分解模型
- 4 基于 GPU 的实时磁共振指纹的字典生成和匹配

基于 TGV_{α}^2 与核范数的压缩感知重建模型

- DCE-MRI 图像中最重要的问题是时间分辨率和空间分辨率之间的权衡
- 高时间分辨率可以提高参数定量分析的准确性
- 高空间分辨率有助于提高医生的临床阅读

基于 TGV_{α}^2 与核范数的压缩感知重建模型

目前基于压缩感知模型的动态 MR 图像重建有两大类：

- L&S: 旨在寻找一个即低秩又稀疏的解

k-t SLR:

$$\min_X \frac{1}{2} \|AX - B\|_F^2 + \alpha \|X\|_{TV} + \beta \|X\|_* \quad (2)$$

这里 $\|\cdot\|_*$ 是矩阵的核范数，即矩阵的奇异值的和，而 $\|X\|_{TV}$ 定义为：

$$\|\cdot\|_{TV} = \sqrt{(\nabla_x \cdot)^2 + (\nabla_y \cdot)^2 + (\nabla_t \cdot)^2},$$

其中 ∇_x , ∇_y 和 ∇_t 分别为 x, y 和 t 方向上的梯度算子。

问题：TV 正则项导致阶梯效应，并且重建图像的边界模糊。

基于 TGV_{α}^2 与核范数的压缩感知重建模型

- L+S: 将动态图像分解为两个部分，低秩部分和稀疏部分。
其中低秩部分用来建模时间上高度相关的背景，稀疏部分用来建模背景之上的动态信息。

TTV+NN:

$$\min_{L,S} \frac{1}{2} \|A(L + S) - B\|_F^2 + \alpha \|\nabla_t S\|_1 + \beta \|L\|_* \quad (3)$$

问题：模型只用到了时间方向的稀疏项，重建模型的空间分辨率低。

基于 TGV_{α}^2 与核范数的压缩感知重建模型

Bredies 提出了基于图像高阶信息的 Total Generalized Variation (TGV) 的理论框架。 TGV_{α}^2 可很好地刻画图像中的平滑部分，在抑制阶梯效应方面有着良好的表现。

针对 TV 正则项导致阶梯效应的问题，并且利用图像分解的思想，我们提出了基于 TGV_{α}^2 和核范数的 L+S 模型：

$$\min_{L,S} \frac{1}{2} \|A(L + S) - B\|_2^2 + TGV_{\alpha}^2(S) + \beta \|L\|_* \quad (4)$$

基于 TGV_α^2 与核范数的压缩感知重建模型

- 三组数据，体模、心脏灌注和胸部 DCE-MRI
- 采样模式为伪径向采样，在每一帧上均匀选取 32 条采样线
- 使用 Primal-Dual 求解
- 评价标准为 SER 和结构相似性测度 (SSIM)

基于 TGV_{α}^2 与核范数的压缩感知重建模型

Table: 伪径向采样模式下不同模型在不同数据上重建结果的比较

Datesets Models		PINCAT	Cardiac	Breast 1	Breast 2
k-t SLR	SER	31.42	18.26	26.99	25.45
	SSIM	0.9935	0.9452	0.9873	0.9627
TTV+NN	SER	29.05	18.72	29.67	29.12
	SSIM	0.9617	0.9455	0.9848	0.9697
Proposed	SER	32.53	19.72	30.53	29.32
	SSIM	0.9852	0.9546	0.9922	0.9759

基于 TGV_{α}^2 与核范数的压缩感知重建模型






Figure: L+S 模型低秩与稀疏分解效果。PINCAT

基于 TGV_{α}^2 与核范数的压缩感知重建模型



基于 TGV_{α}^2 与核范数的压缩感知重建模型



- 1 引言
- 2 胸部 DCE-MRI 图像压缩感知的时间稀疏正则项的量化评估
- 3 动态 MRI 图像的低秩和稀疏分解模型
- 4 基于 GPU 的实时磁共振指纹的字典生成和匹配

GPU 程序实现

- MRF 重建参数图的过程中需要生成一个包含不同参数的组织随着时间演化的字典，而这个过程十分耗时，尤其是使用扩展相图模型 (EPG) 进行字典模拟时。
- 采集信号后，需要将信号与字典进行匹配，从而重建出参数图。这个过程需要计算向量的内积，当字典个数和指纹体素个数很多时，计算的代价也会很大。

GPU 程序实现

针对 MRF 重建参数图计算时间长的问题，我们开发了一款开源有效的 MRF 重建软件 snapMRF，用于在 GPU 上平行计算字典生成和模板匹配。snapMRF 的代码结构入下：

- CSV 文件中读取 MR 序列的成像参数
- 从命令行读取字典的配置信息 (T_1 , T_2 , B_0 , B_1^+)
- 直接在 GPU 上生成字典
- 将指纹体素与字典匹配
- 保存结果

GPU 程序实现

- 我们和另外两款开源的软件进行比较，它们分别是 EPG-X(MATLAB, CPU) 和 PnP-MRF(C, CPU)。
- 从运行时间和重建参数质量两方面进行比较
- 体模数据和活体人脑数据

实验结果




Figure: snapMRF 与 EPG-X

基于 TGV_{α}^2 与核范数的压缩感知重建模型

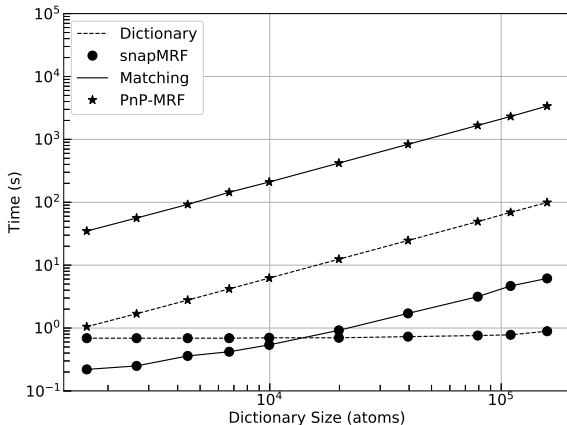


Figure: snapMRF 与 PnP-MRF

实验结果

Table: snapMRF 与 EPG-X 在字典生成和模板匹配上运行时间的比较。字典大小为 100,000，指纹体素个数为 240×240 。注意 snapMRF 比 EPG-X 快很多。

Running time (ms)	EPG-X fixT _R	snapMRF fixT _R	snapMRF varT _R	snapMRF varT _R +B ₁ ⁺
phantom/dict	17797.05	11.00	7.42	9.39
phantom/match	137.13	5.97	4.14	4.88
brain/dict	18629.82	11.29	7.63	8.72
brain/match	143.55	6.13	4.23	4.63

实验结果


True T_1 (ms)	EPG-X $\text{fix}T_R$	snapMRF $\text{fix}T_R$	snapMRF $\text{var}T_R$	snapMRF $\text{var}T_R/wB_1^+$
90.9	128.5	127.7	111.5	94.2
126.9	155.0	155.0	146.5	127.9
176.6	173.1	173.1	172.3	153.8
244.2	280.4	280.4	265.0	225.0
336.5	342.7	342.7	326.5	319.2
458.4	471.2	471.2	471.9	468.3
608.6	602.7	601.2	625.0	622.1
801.7	771.5	770.4	818.5	813.5
1044.0	945.0	943.1	1032.3	1026.0
1332.0	1262.7	1263.1	1310.8	1306.7
1604.0	1568.8	1568.1	1607.3	1593.3
1907.0	1861.2	1861.9	1854.2	1828.8
2173.0	2043.1	2043.1	2091.9	2094.2
2480.0	2366.5	2366.2	2434.6	2416.3
err (%)	4.9	5.0	2.6	3.0

(a) T_1 精度


True T_2 (ms)	EPG-X $\text{fix}T_R$	snapMRF $\text{fix}T_R$	snapMRF $\text{var}T_R$	snapMRF $\text{var}T_R/wB_1^+$
5.6	6.9	6.9	9.4	12.3
7.9	11.5	11.2	10.0	13.5
11.2	13.3	13.3	11.2	13.5
15.8	13.7	13.5	11.3	20.4
22.6	21.2	21.2	23.3	30.0
32.0	32.3	32.3	38.3	47.3
46.4	45.0	44.8	50.4	60.0
64.1	64.2	64.2	70.2	83.8
96.9	84.6	84.4	90.8	104.6
133.3	144.0	143.8	146.9	170.8
190.9	175.4	175.4	185.2	213.8
278.1	266.5	266.5	255.4	290.0
403.5	323.3	323.5	343.7	407.7
581.3	474.0	474.2	453.5	531.5
err (%)	16.9	16.9	17.9	9.3

(b) T_2 精度

实验结果



实验结果



非常感谢大家来参加我的博士论文学位答辩！
谢谢大家的帮助和指导！